Mesure d'entropie asymétrique et consistante

Djamel A. Zighed*, Simon Marcellin*
Gilbert Ritschard**

*Université Lumière Lyon 2, Laboratoire ERIC {abdelkader.zighed,simon.marcellin}@univ-lyon2.fr http://eric.univ-lyon2.fr **Université de Genève, Département d'économétrie, Suisse gilbert.ritschard@unige.ch

Résumé. Les mesures d'entropie, dont la plus connue est celle de Shannon, ont été proposées dans un contexte de codage et de transmission d'information. Néanmoins, dès le milieu des années soixante, elles ont été utilisées dans d'autres domaines comme l'apprentissage et plus particulièrement pour construire des graphes d'induction et des arbres de décision. L'usage brut de ces mesures n'est cependant pas toujours bien approprié pour engendrer des modèles de prédiction ou d'explication pertinents. Cette faiblesse résulte des propriétés des entropies, en particulier le maximum nécessairement atteint pour la distribution uniforme et l'insensibilité à la taille de l'échantillon. Nous commençons par rappeler ces propriétés classiques. Nous définissons ensuite une nouvelle axiomatique mieux adaptée à nos besoins et proposons une mesure empirique d'entropie plus flexible vérifiant ces axiomes.

1 Introduction

Dans les méthodes qui génèrent des règles de décision du type **Si** condition **Alors** Conclusion comme les arbres de décision (Breiman et al., 1984; Quinlan, 1993), les graphes d'induction (Zighed et Rakotomalala, 2000),... les mesures d'entropie sont fréquemment utilisées. Or celles-ci reposent sur de nombreuses hypothèses implicites qui ne sont pas toujours justifiées.

Les mesures d'entropie ont été définies mathématiquement par un ensemble d'axiomes en dehors du contexte de l'apprentissage machine. On peut trouver des travaux détaillés dans Rényi (1960), et Aczél et Daróczy (1975). Leur transfert vers l'apprentissage s'est fait de manière peut-être hâtive et mérite d'être revu en détail.

Le présent travail examine et discute des propriétés des entropies dans le cadre des arbres d'induction.

Dans la section suivante, nous fixons quelques notations et rappelons le contexte d'utilisation des mesures d'entropie. Dans la section 3, nous présentons les mesures d'entropie et discutons leurs propriétés et leurs conséquences dans les processus d'induction. Dans la section 4, nous proposons une axiomatique conduisant à une nouvelle mesure d'entropie.