

Inférence dans les HMM hiérarchiques et factorisés : changement de représentation vers le formalisme des Réseaux Bayésiens.

Sylvain Gelly*, Nicolas Bredeche*, Michèle Sebag*

*Equipe Inference&Apprentissage - Projet TAO (INRIA futurs),
LRI, Université Paris-Sud, 91504 Orsay Cedex
(gelly,bredeche,sebag)@lri.fr

1 Présentation du problème

Une limite essentielle des HMM, et plus généralement des modèles de Markov, concerne le passage à l'échelle, l'impossibilité de la prise en compte efficace de l'influence de phénomènes indépendants et la difficulté de généralisation.

Pour répondre à ces problèmes, plusieurs extensions existent. En particulier, nous nous intéresserons dans ce qui suit à la *hiérarchisation* (Theocharous et al. 2001, 2004) et à la *factorisation* (Ghahramani 1996).

La hiérarchisation permet de réduire le nombre de liens entre états nécessaires dans un HMM et par là même de réduire la complexité algorithmique de l'apprentissage ainsi que l'imprécision. Quant à la factorisation, le principe est d'expliquer les observations par plusieurs causes plutôt qu'une seule. C'est à dire qu'on remplace le $P(Y|X)$ des HMM par $P(Y|X^1, X^2, \dots, X^n)$. Les X^i sont des variables cachées pouvant être gérées indépendamment. Les $P(X_{t+1}^i | X_t^i)$ sont alors différents pour chaque i .

- L'existence de dépendances multiples dans les FHHMM entraîne a priori une explosion combinatoire du nombre de paramètres à apprendre, ce qui est d'autant plus problématique lorsque peu d'exemples sont à notre disposition (ceci est une propriété inhérente à la robotique);
- La présence de circuits dans les dépendances conditionnelles entre les variables d'un FHHMM empêchent la modélisation directe par un réseau bayésien. Il est à noter que ces dépendances ne concernent les variables qu'à un même pas de temps (synchrones).

Dans la suite de cet article, nous ne ferons pas de différence entre les dépendances synchrones et les transitions temporelles, les deux types étant des *dépendances conditionnelles* entre deux variables.

On ne peut ainsi pas adapter directement les algorithmes existants dans le cas des HMM factorisés, ou hiérarchiques.

Un aspect important du problème est que notre système apprend à partir de données éparées car nous faisons l'hypothèse que nous ne disposons que d'un petit nombre d'exemples pour apprendre. Ceci se justifie par le domaine d'application (la robotique située), où le processus d'échantillonnage des données est contrôlé par un comportement dépendant entre autres de l'environnement et des capacités du robot qui ne permet pas d'obtenir beaucoup d'exemples. Par conséquent, nous souhaitons exprimer un compromis entre précision et vitesse de l'apprentissage.