Analyse statistique de similarité dans une collection d'images

Madenda Sarifuddin**, Rokia Missaoui*, Jean Vaillancourt*
Youssef Hamouda** et Marek Zaremba*

* Département d'informatique et d'ingénierie, Université du Québec en Outaouais e-mail: rokia.missaoui/jean.vaillancourt/marek.zaremba@uqo.ca

** Département d'informatique, Université du Québec à Montréal
C.P. 8888, succursale Centre-Ville, Montréal, Québec, Canada, H3C 3P8
e-mail: madenda@info.uqam.ca; hamouda.youssef@courrier.uqam.ca

Résumé. Dans le cadre du développement d'un système de recherche d'images par le contenu, nous avons défini deux nouvelles mesures : la distance de dissimilitude DS*, et la distance de similarité E. La seconde est intégrée à la formule de la distribution de Gibbs et de celle de la mixture de Dirichlet généralisée, alors que la première est comparée à trois autres variantes d'estimation de la similarité : la distance Euclidienne ainsi que les distributions de Gibbs et Dirichlet intégrant la distance de similarité E. L'analyse empirique des quatre mesures de similarité porte sur les histogrammes de couleurs d'une collection d'images et montre que l'efficacité de la recherche, mesurée par le rappel et la précision, est la plus importante pour la distribution de Dirichlet modifiée et la plus faible pour la distance Euclidienne.

Mots-clés. Recherche d'images par le contenu, mesures de similarité, distribution de Dirichlet, distribution de Gibbs.

1 Introduction

La caractéristique visuelle la plus fréquemment utilisée dans la recherche d'images par le contenu est la couleur. Cette dernière est relativement robuste et indépendante de la taille et de la transformation géométrique de l'image. Les valeurs de la couleur sont d'habitude calculées dans les espaces de couleur correspondant à la perception humaine tels que HSV, L*a*b* ou L*u*b*, soit d'une manière approximative par identification d'un éventail de couleurs présentes dans l'image, soit d'une manière plus précise sous forme d'histogrammes.

Dans (Missaoui et al. 2003), nous proposons une approche de recherche d'images par le contenu (Rui et al. 1999) qui effectue deux types d'analyse de similarité: une analyse approximative (coarse-grain) faisant appel à une technique de regroupement conceptuel appliquée aux caractéristiques visuelles (couleurs et formes) exprimées sous forme d'une relation binaire entre une collection d'images et leurs propriétés, et une analyse fine (fine-grain) qui effectue un calcul de similarité sur des histogrammes de couleurs. Dans les deux types d'analyse, les caractéristiques visuelles sont automatiquement extraites à partir des images. La première analyse vise à faire de la fouille de données (data mining) sur une collection d'images en identifiant des concepts (ex. les images 2 et 6 possèdent le bleu, le vert et des lignes) et des règles d'association (ex. si des images comportent des courbes, alors il y a 60% de chances pour qu'elles puissent aussi contenir la couleur verte).