'Discussion sur les prédicteurs conformes proposés par Alex Gammerman et Vladimir Vovk'

Alexey Chervonenkis

Research Institute of Control Problems, Russian Academy of Sciences Computer Learning Research Centre, Royal Holloway, University of London, UK chervnks@ipu.rssi.ru

Mots clés: apprentissage automatique, prédicteurs conformes, complexité de Kolmogorov, approche bayésienne, étrangeté d'une prédiction

Abstract: Conformer predictors approach seems to be new and powerful. Its main advantage is that it is non-parametric and based only on the i.i.d. assumption. In comparison to the Bayesian approach, no prior distribution is used. The main theoretical result is the proof of validity of proposed conformal predictors. The second result is that asymptotically the relative number of cases when the real output value is within confidence interval converges to the average value of conformal predictors. The proposed technique is now applied to a large variety of practical problems. Two drawbacks of the approach are still mentioned in this discussion

Keywords: Machine Learning, conformer predictor, Kolmogorov complexity, Bayesian approach, prediction strangeness

Il y a aujourd'hui de nombreux algorithmes d'Apprentissage Automatique très diversifiés qui sont développés et appliqués dans les différents domaines scientifiques et industriels. Mais cette nouvelle approche comportait jusqu'à présent un certain inconvénient : on ne peut calculer un degré de confiance à accorder à la prédiction d'une valeur pour les nouveaux objets.

L'idée principale de l'article des professeurs Alex Gammerman et Vladimir Vovk est de considérer toutes les étiquettes possibles pour un nouvel élément et d'évaluer l'étrangeté de chaque appellation en comparaison de celles des objets de l'ensemble d'apprentissage. Tout le problème est de trouver une mesure intéressante pour cette 'étrangeté'. Dans un premier temps les auteurs tentent d'appliquer les idées de la complexité selon Kolmogorov pour estimer l'étrangeté des étiquettes. Mais la complexité n'est d'une part pas calculable, de plus elle n'est définie qu'à une constante près, et enfin elle n'a de sens que pour l'entière séquence des objets, et non pas pour l'un d'entre eux en particulier.

Les auteurs proposent alors une autre idée (toujours en liaison avec la complexité chez Kolmogorov) pour estimer cette étrangeté des étiquettes. C'est pour chaque algorithme particulier d'apprentissage, qu'on envisage de trouver une mesure raisonnable de l'étrangeté de l'étiquette attribuée à un objet. Pour la régression (ou la régression Ridge) cette mesure peut être choisie comme la différence absolue entre le résultat de la régression et le résultat réel : plus grande est la différence, plus 'étranger' est l'objet. Dans une approche SVM de reconnaissance de formes, cela

peut être les poids des vecteurs de support : plus les poids sont importants, moins la confiance dans les étiquettes est grande ; des mesure analogues d'étrangeté peuvent être envisagées pour les autres algorithmes.

La démarche est finalement la suivante : on parcourt tout l'éventail des étiquettes pour un nouvel objet. Pour chaque possibilité, on adjoint cette réalisation à l'ensemble d'apprentissage. On déroule ensuite l'algorithme d'apprentissage et l'on ordonne les objets par la mesure d'étrangeté choisie. On estime la confiance en l'étiquette par la différence à un de la proportion, dans l'ensemble d'apprentissage complet, d'objets plus étrangers que le nouveau.

Cette approche nous semble nouvelle et pleine de promesses. Son point fort est qu'il s'agit d'une méthode non paramétrique et la seule hypothèse que l'on fait est celle i.i.d. de distribution identique et indépendante des données. Par rapport à l'approche bayésienne, on n'a besoin ici d'aucune distribution a priori. Le résultat théorique le plus important est la démonstration de la validité des prédicteurs conformes. Cette validité consiste en ceci : jamais en moyenne les prédicteurs conformes ne surévaluent dans leur prédiction les niveaux de précision et de confiance. De plus l'autre résultat important est que la proportion des cas où la valeur réelle est à l'intérieur d'un certain intervalle de confiance converge asymptotiquement vers la valeur moyenne des prédicteurs conformes.

On a déjà développé et implémenté différentes versions de ces recherches pour un grand éventail d'applications. Je voudrais cependant mentionner deux points de cet article qui me semblent encore sujets à caution:

- 1. Il n'y pas de considération théorique sur le degré d'optimalité des intervalles de confiance suggérés pour chaque objet. Dans le cas général, il pourrait se produire que pour certains objets, l'intervalle soit trop grand, et que pour d'autres il soit par contre trop restreint, alors qu'en moyenne ce qu'on nomme 'validité' dans cet article soit bon. Pour l'approche bayésienne, on peut prouver l'optimalité, mais il faut une poser une distribution a priori. On présente justement dans le texte les résultats expérimentaux de comparaisons avec l'approche bayésienne, mais seulement dans des cas précis où l'on constate que les résultats sont très proches des résultats optimaux. Nous pensons cependant qu'une étude théorique de la question serait pertinente.
- 2. Dans les problèmes de reconnaissance des formes, on propose une mesure du niveau de confiance par le calcul suivant : la différence à un du deuxième niveau le plus grand repéré par l'ordre du degré de hasard. Il nous semblerait plus judicieux d'utiliser comme formule la différence entre la plus grande des valeurs et la suivante. Par exemple dans la table 1, ligne 3, on voit que la crédibilité n'est que de 1.43%, alors que le niveau de confiance est de 98.93%. Si on considère la différence entre la première meilleure valeur et la deuxième meilleure, le niveau de confiance devient très faible, et effectivement, dans ce cas précis, la prédiction était fausse.