Sandrine Coelho*, Christine Thomas-Agnan**, Nicolas Lassabe***, Yves Duthen***

Université des Sciences Sociales (UT1)-Manufacture des Tabacs
21, Allée de Brienne -31000 Toulouse
*sandrine.coelho@univ-tlse1.fr
Entreprise GéoSignal
**cthomas@cict.fr
Laboratoire GREMAQ
***lassabe@irit.fr
Laboratoire IRIT-UT1, entreprise GéoSignal
****duthen@irit.fr
Laboratoire IRIT-UT1

Résumé. La plate-forme DynaSpat¹ est une plate-forme de simulation et de visualisation pour la description, l'analyse et la modélisation de comportements d'acteurs économiques. Elle intègre un ensemble de logiciels et de bibliothèques permettant d'exécuter des simulations basées sur les algorithmes génétiques et de résumer une information complexe, issue d'un jeu de données, par des variables pertinentes. Elle permet ainsi de comprendre l'influence réciproque entre la structuration d'un territoire et des comportements d'acteurs économiques ou sociaux.

1. Introduction

L'étude des dynamiques spatiales s'applique à des données complexes et hétérogènes provenant de sources multiples, il est donc indispensable de disposer d'outils permettant de les interpréter et d'en retirer des connaissances. Pour cela, il faut maîtriser plusieurs disciplines telles que les sciences et technologies de l'information, l'économie, la sociologie, la statistique et la géographie.

Nous pouvons constater que bien des outils sont développés en ce qui concerne le stockage, l'extraction et la visualisation de données. Ils sont optimisés pour leur domaine d'application mais, de ce fait, leur utilisation est parfois trop spécifique. De plus, on peut remarquer que bien souvent le couplage de ces modules peut s'avérer difficile et que les outils d'analyse disponibles s'avèrent insuffisants. Notre approche consiste à réunir et compléter ces techniques dans un environnement unique.

L'objectif du projet DynaSpat est d'expliquer l'émergence, dans une zone géographique donnée, de comportements spécifiques d'acteurs économiques, tout en permettant la convergence de plusieurs champs disciplinaires. Nous avons créé un outil global permettant d'utiliser un outil d'optimisation (AGMC) et de coupler une carte avec un ensemble de techniques statistiques spatiales (GéoXP) dialoguant de façon interactive. Le principal apport

¹ Remerciements : ce projet de recherche est supporté par la région Midi-Pyrénées et regroupe trois laboratoires : IRIT, GREMAQ, LEREPS, et l'entreprise GéoSignal.

de notre démarche est d'introduire, à tous les niveaux de notre réflexion, le territoire comme facteur déterminant dans le comportement des acteurs économiques.

Nous allons présenter dans un premier temps l'architecture de la plate-forme DynaSpat. Nous détaillerons ensuite chacun des modules de statistique et d'optimisation qui sont intégrés au sein de la plate-forme, en montrant leur caractère novateur.

2. La plate-forme DynaSpat

Le projet DynaSpat est issu d'un appel d'offre régional encourageant l'émergence de projets fédératifs de recherche, autour de thématiques clés, réunissant plusieurs laboratoires, en partenariat avec des PME-PMI et des acteurs de l'économie régionale.

La plate-forme regroupe plusieurs modules issus de recherches en statistique et en optimisation effectuées dans des laboratoires universitaires (l'IRIT-UT1 : Institut de Recherche en Informatique et le GREMAQ : Groupe de Recherche en Economie Mathématique et Quantitative, de l'université des Sciences Sociales de Toulouse). Ces chercheurs ont réuni leurs connaissances et leurs expériences en tant qu'utilisateurs d'outils, afin de développer des bibliothèques. Deux modules sont issus de ce travail, la bibliothèque d'analyses statistiques spatiales GéoXP et la bibliothèque d'algorithmes génétiques multicritères AGMC.

Deux logiciels industriels ont également été intégrés, le premier est le Système d'Informations Géographiques (SIG) GéoConcept, et le second est le moteur de visualisation 3D VirtualGéo.

La figure ci-dessous présente l'architecture de la plate-forme.

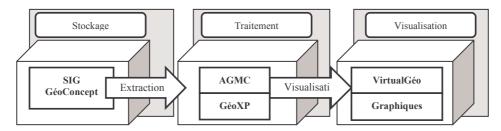


FIG. 1 - Architecture de la plate-forme DynaSpat

Les deux bibliothèques utilisent des données qui sont stockées et extraites du SIG GéoConcept que nous allons vous présenter.

2.1 Stockage des données

Les Systèmes de Gestion de Bases de Données (SGBD) sont spécialisés et optimisés dans le stockage, la gestion et l'extraction de tout type d'informations y compris les informations géographiques, mais ils ne permettent pas de visualiser l'information. Le Système d'Informations Géographiques (SIG) issu des SGBD, « est un système informatique permettant, à partir de diverses sources, de rassembler et d'organiser, de gérer, d'analyser et de combiner, d'élaborer et de présenter des informations localisées géographiquement contribuant notamment à la gestion de l'espace » (définition adoptée par le comité

scientifique du colloque intégration de la photogrammétrie et de la télédétection dans les SIG SFPT, à Strasbourg en 1990). Quatre fonctionnalités d'un SIG ont été décrites par Burrough [Burrough, 1986], la saisie, le stockage, l'analyse et la visualisation des données.

Au sein de la plate-forme DynaSpat, le SIG GéoConcept permet de stocker des données servant à l'analyse statistique et spatiale et à l'optimisation d'une problématique, mais aussi, d'apporter une représentation 2D du territoire sur laquelle sera effectué l'ensemble des analyses spatiales.

Les paragraphes suivants exposent plus en détail les traitements de données réalisables grâce à la plate-forme. Dans une première partie, nous présentons la bibliothèque d'analyse statistique spatiale GéoXP à travers les fonctionnalités qu'elle propose, son rôle dans l'identification de variables pertinentes et l'interprétation de données, puis dans une seconde partie, la bibliothèque AGMC à travers les processus d'optimisation.

3. Analyse statistique spatiale

3.1 L'analyse statistique de données géoréférencées

Les données géoréférencées sont des données comportant une dimension spatiale, c'est-à-dire pour lesquelles une information géographique est attachée à chaque unité spatiale. L'information géographique est en général la position de l'unité sur une carte ou dans un référentiel spatio-temporel et peut, par exemple, prendre la forme de latitude et longitude ou de coordonnées UTM. Un traitement statistique de telles données qui ignorerait cet aspect ou l'intégrerait de façon inadéquate résulterait en une perte d'informations, des erreurs de spécifications, des estimations non convergentes et non efficaces. En effet il ne suffit pas de juxtaposer l'analyse géographique à l'analyse statistique, il faut les faire interagir.

L'analyse spatiale, qui est l' « étude formalisée de la configuration et des propriétés de l'espace produit et vécu par les sociétés humaines » [Pumain et Saint-Julien, 1997] permet de mettre en évidence des règles générales d'organisation d'un espace donné. Les progrès continuels de l'informatique donnent au chargé d'études l'accès à des données de plus en plus nombreuses et de plus en plus complexes. L'analyse exploratoire de données géoréférencées [Wise et al. 2001] doit prendre en compte leur dimension spatiale. Les SIG permettent de faire de la cartographie très évoluée mais n'intègrent pas d'outils statistiques très sophistiqués et en particulier les outils adaptés aux données spatiales [Cressie, 1993]. L'analyste doit alors utiliser d'une part un logiciel cartographique et un ou plusieurs logiciels statistiques. L'outil d'analyse spatiale qui a été développé permet de coupler une carte et un ensemble de graphiques statistiques [Monmonier, 1989].

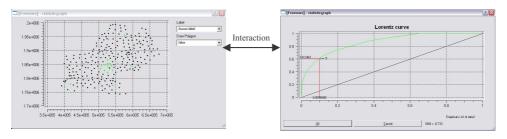


FIG. 2 - Interface de la représentation d'une courbe de Lorentz par GéoXp

Voici (figure 2) un exemple d'analyse réalisable avec GéoXp pour étudier la concentration des femmes médecins en Midi-Pyrénées, les cantons comptant plus de 5 femmes médecins se concentrent dans les zones fortement urbaines.

3.2 GéoXp une bibliothèque d'analyse spatiale

A l'heure actuelle, la bibliothèque GéoXp, développée par le GREMAQ, incorpore un bon nombre d'outils d'analyse exploratoire (cf. Annexe 1) provenant à la fois de la géostatistique et de l'économétrie spatiale, deux champs distincts de la statistique spatiale. Cette double coloration en fait son originalité car la plupart des projets similaires sont issus d'un champ ou de l'autre. Les buts principaux des méthodes proposées par GéoXP sont d'étudier des tendances (ou variations à large échelle) dans une variable donnée, des phénomènes d'auto-corrélation spatiale (agrégations spatiales de points semblables du point de vue de la variable étudiée, ou au contraire dissemblables), ou d'identifier des points atypiques. La présence de techniques de réduction de dimension (analyse en composantes principales, régression inverse, projection poursuite) en liaison avec la carte différencie également cette bibliothèque de ses concurrentes et permet de traiter des données multidimensionnelles. La bibliothèque comporte aussi une fonction de classification de données spatiales.

Un point important ne doit cependant pas être négligé : il s'agit de la représentation de données. L'analyse ne peut se faire convenablement que si les informations visuelles présentées sont adaptées à la perception de l'analyste. De plus, le couple représentation interaction permet une meilleure appréhension de l'information. Ce sont ces deux points que nous allons examiner.

4. Perception visuelle et interactions

L'objectif général de la visualisation de l'information est de faciliter son interprétation, en particulier lorsque celle-ci est abondante et hétérogène car provenant de sources multiples.

Certains travaux en perception visuelle ont souligné l'importance de différentes échelles perceptives [Myers, 2000] [Triesman, 1985, 1988, 1991]: face à un ensemble complexe d'informations l'être humain a d'abord une perception globale, puis il porte son attention aux détails [Schneiderman, 1996]. Les travaux de Tufte [Tufte, 1983], Bertin [Bertin, 1977] et Turkey [Turkey, 1977] ont montré comment exploiter les caractéristiques de perception globale. Ils ont ouvert une autre approche de l'usage du graphisme dans les méthodes de traitement de l'information. Il s'agit de visualiser les données qualitatives ou quantitatives par différentes méthodes afin d'orienter, a priori, la réflexion de l'analyste.

Les caractéristiques du système visuel humain pour la manipulation et l'interprétation de données sont exploitées pour la visualisation d'informations. Les tâches rencontrées en visualisation d'informations sont liées à la recherche d'informations au sens large :

- exploitation rapide d'ensembles d'informations inconnues,
- mise en évidence de relations de structures dans les informations,
- mise en évidence de chemins d'accès à des informations pertinentes,
- classification interactive des informations.

4.1 Perception graphique

Les graphiques illustrent les résultats obtenus par des méthodes statistiques et présentent ainsi une information par une image. Selon Goldenweiser [Goldenweiser, 1916] les graphiques ne sont pas là pour traiter les données, mais pour afficher les résultats. Avant d'étudier la perception graphique, il faut déterminer les objectifs d'un graphique. Goldenweiser classe les graphiques de la manière suivante :

- les graphiques référentiels qui permettent de présenter autrement une information déjà connue par le lecteur,
- les graphiques illustratifs qui servent à fixer un fait important dans l'esprit du lecteur et font appel à la mémoire visuelle. Ils peuvent être un peu plus complexes que les précédents dans la mesure où ils illustrent le texte en soulignant un point fondamental,
- les graphiques analytiques qui mettent en évidence une relation,
- les graphiques de recherche qui permettent d'aider à établir une relation inconnue.

Cleveland et McGill [Cleveland et McGill, 1984] ont cherché les éléments du graphique auxquels nous réagissons, ce qui a donné lieu à une liste de 10 primitives graphiques, classées par ordre décroissant de performance, qui correspondent aux aspects géométriques et textuels des graphiques. En observant ces éléments, le lecteur extrait visuellement de l'information. Voici ces différents éléments : position sur une échelle commune, position sur des échelles non alignées, longueur, angle, pente, aire, volume, densité, saturation de la couleur, tonalité de la couleur. Par exemple, ils ont observé que le code élémentaire majeur pour l'histogramme circulaire est la position sur une échelle commune.

De plus, Pinker [Pinker, 1981] a défini quatre classes de processus de perception graphique qui peuvent d'écrire un modèle cognitif de perception graphique :

- des processus d'appariement qui déterminent quel type de graphique (histogramme, histogramme empilé, diagramme circulaire) est présenté et qui activent des schémas de lecture de bas en haut du graphique,
- des processus d'assemblage du message qui transforment l'information de la vision première en une image conceptuelle,
- des processus d'intégration qui tirent de l'information des données rétiniennes et des schémas graphiques génériques pour faire apparaître les relations et les valeurs qui manquent à l'image mentale et donner une relation du type « plus petit que », « plus grand que »...
- des processus inférentiels qui utilisent l'image mentale et le schéma graphique générique pour en dériver de nouvelles relations et valeurs (calculer la proportion relative d'une division par rapport à une plus grande).

Un graphique est donc « correct » s'il arrive à communiquer l'information que son auteur a voulu faire passer.

Les études menées sur la perception mais aussi sur la psychologie et les sciences cognitives, l'ergonomie et la sociologie ont permis de faire évoluer les systèmes d'interaction : « L'indissociabilité de la perception, de la décision et de l'action modificatrice de l'univers perçu, instaure une boucle qui place décision et action sur le même plan que la perception dans le processus de cognition » [Vallée, 1996].

Après avoir réfléchi sur les algorithmes à développer pour disposer d'une bibliothèque d'analyse spatiale complète, il a fallu se poser les bonnes questions concernant la

représentation des données et l'interaction, cette dernière ayant une place importante dans le processus d'analyse.

5. Représentation de l'information par GéoXp

Nous souhaitons faciliter le travail de l'analyste en proposant des interfaces graphiques conviviales qui mettent en évidence des résultats ou des informations pertinentes.

Pour cela nous nous sommes efforcés de créer une unité entre les graphiques, d'organiser les interfaces, d'utiliser une charte de couleurs [Healey, 1996], d'utiliser le symbolisme (point, triangle, courbe...), le but étant de fournir à l'analyste un maximum d'informations lors de la première lecture.

Nous considérons que les informations dont l'analyste disposera peuvent être classées en deux types d'informations : celles qui sont immédiatement « accessibles » par une observation de l'interface, et celles qui sont « apprises » soit par une analyse soit par des interactions. Nous allons nous intéresser dans un premier temps à la première catégorie de données.

5.1 L'information « accessible »

Chacune des interfaces graphiques proposées ont leurs particularités mais nous avons établi certaines règles de représentations communes afin de faciliter l'adaptation visuelle de l'utilisateur lorsqu'il passe d'un graphique à l'autre. Ces règles concernent, comme il a été dit précédemment, l'organisation de l'information, l'utilisation des couleurs et des symboles. La figure 3, qui présente une interface graphique type, est composée d'un ensemble d'informations textuelles ordonnées, de la représentation d'un graphique, et éventuellement d'un ensemble d'objets permettant une interaction.

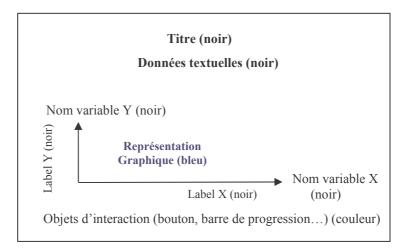


FIG. 3 - Interface graphique

Au premier affichage d'un graphique, et ce de manière générale, tous les textes sont affichés en noir et les représentations graphiques (courbes, symboles...) en bleu. L'analyste

connaît dès lors le type de graphique, le nom des variables utilisées, le référentiel spatial utilisé et un ensemble de résultats liés aux calculs. Les unités spatiales de la carte associée au graphique sont des points noirs liés à une échelle spatiale. Il s'agit là des informations minimales accessibles par l'observateur sur toutes les interfaces. L'observateur n'a pas d'effort d'accommodation, il peut se consacrer à l'analyse.

Cependant l'utilisateur a le choix de la qualité et de la quantité d'informations qu'il visualise grâce à un ensemble d'options. Par exemple, ayant sélectionné une unité spatiale de la carte, il juge que la valeur pour cette unité du vecteur de données ayant servi à construire le graphique est une information utile à l'analyse de son problème. Il peut alors demander l'affichage d'un label représentant cette donnée. Cet affichage peut être activé ou désactivé à chaque instant. L'utilisateur a donc la possibilité d'adapter l'interface à sa capacité visuelle et à sa capacité d'intégration de données, mais aussi au type d'analyse qu'il souhaite effectuer.

Nous n'avons parlé que de la visualisation des « données brutes », il reste cependant un second type de données proposé indirectement à l'utilisateur que l'on appelle données « apprises ».

5.2 Les informations « apprises »

On peut considérer les données « apprises » comme l'ensemble des informations qui ne sont pas accessibles immédiatement mais seulement lors de la boucle décision, action.

Deux types d'interaction, présentés par la figure 4, sont possibles : la sélection (interne ou externe) et l'interaction dynamique. Dans ce qui suit nous appelons sélection interne celle qui est générée et interceptée par une même interface, il s'agit donc de « la propre sélection » d'un graphique. La sélection externe est la sélection qui est reçue par un graphique et qui est produite par une sélection sur une autre interface.

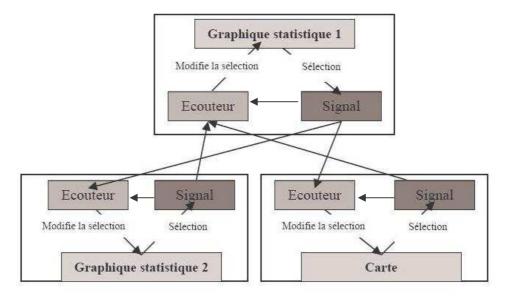


FIG. 4 - Dialogues entre les graphiques et la carte

Si les caractéristiques du graphique affiché permettent à celui-ci de recevoir une sélection externe alors cette sélection provoquera un affichage vert des modifications graphiques, de même s'il peut recevoir des sélections internes alors ces modifications seront rouges. L'utilisateur peut sélectionner une ou un ensemble d'unités spatiales à l'intérieur d'un polygone de sélection ce qui génère un « vecteur de sélection ». Ce vecteur de sélection peut également servir à analyser, a posteriori, les caractéristiques de la sélection. De plus du fait de la création d'un lien entre les données géoréférencées et l'analyse statistique, une de ces sélections met en évidence de la même manière les unités spatiales représentées sur la carte. L'utilisateur peut ainsi sélectionner et désélectionner à sa guise à l'aide de la souris. Le dialogue créé entre les interfaces de graphiques statistiques, qui proposent leurs propres résultats, et la carte constitue de nouvelles informations permettant à l'analyste d'affiner son expertise.

L'utilisation d'objets d'interaction (bouton, barre de progression...) peut modifier les informations textuelles et graphiques, l'interface est transformée dynamiquement. Prenons comme exemple un angleplot (figure 5), ce graphique met en évidence les directions dans lesquelles la variable présente des tendances. Il relie une carte et un nuage de points. Le graphique statistique consiste à présenter pour tous les couples de sites dont le segment forme un angle σ (en radian) avec l'horizontale, la valeur absolue de la différence entre les valeurs de la variable étudiée en ces sites. A ce graphique sont associées plusieurs options de calcul. En particulier l'option 2 permet la superposition au nuage de points d'une courbe représentant l'estimateur à noyau de la moyenne, mais aussi l'insertion d'un objet d'interaction dynamique (« slider »). Cette courbe représente un lissage défini en fonction d'une valeur d'un paramètre de lissage. La création de cet objet d'interaction est intéressante car il permet de modifier la valeur du paramètre de lissage et donc de reconstruire dynamiquement l'estimateur à noyau de la moyenne en fonction de cette nouvelle valeur.

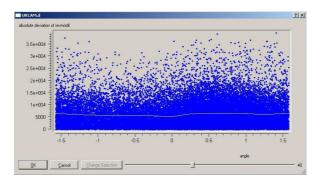


FIG. 5 - Le graphique statistique angleplot (option 2)

L'analyste peut donc compléter ou comparer ses résultats avec plusieurs paramètres de lissage.

Enfin GéoXp est une bibliothèque complète qui associe le calcul, la visualisation et l'interaction au sein d'un même outil, et elle n'utilise pas de logiciels commerciaux. Notre objectif étant la diffusion de cet outil, ce point reste donc très important car bien souvent les licences des outils statistiques sont très onéreuses.

Le second outil intégré au sein de la plate-forme est la bibliothèque des algorithmes génétiques multi-critères l'AGMC. Comme nous allons le montrer par la suite, les processus d'optimisation qu'elle propose servent à de nombreux problèmes qui peuvent s'avérer complexes comme l'optimisation en environnement dynamique, le placement ou déplacement optimal, la simulation comportementale.

6. Optimisation

La plate-forme DynaSpat sert à identifier dans une base de données des variables pertinentes qui serviront ensuite à paramétrer un problème pour permettre l'aide à la décision. Les problèmes ici abordés sont le plus souvent complexes et nécessitent donc d'être traités par des métaheuristiques qui, contrairement aux algorithmes déterministes, apportent le plus souvent des solutions. Parmi ces outils d'optimisation, notre choix s'est porté sur les algorithmes évolutionnistes et en particulier les algorithmes génétiques.

6.1 L'optimisation par les algorithmes génétiques

Les algorithmes génétiques permettent un bon compromis entre l'exploration et l'exploitation d'un grand espace de recherche [Beasley 1993a]. Ils n'ont de contraintes de continuité ni sur la fonction objectif, ni sur leur dérivée et leur robustesse est une des caractéristiques principales ce qui leur permet de s'appliquer dans beaucoup de domaines.

L'optimisation en environnement dynamique pose une nouvelle problématique car les méthodes d'optimisation doivent être capables, non seulement, de trouver l'optimum de la fonction, mais également, de suivre ou de conserver cet optimum au cours du temps. Dans un système dynamique, la qualité de la solution trouvée sera un critère moins déterminant que pour les méthodes d'optimisation en environnement stationnaire. Par contre, la robustesse de ces méthodes sera évaluée par rapport à leurs capacités à détecter un changement et à fournir une réponse appropriée. De nombreuses techniques utilisent un mécanisme de détection exogène qui rend leur efficacité très dépendante de la qualité de ce mécanisme. Peu de méthodes offrent une réponse discriminante à un changement d'environnement. Dès lors, le temps de réponse à ce changement et le risque de détruire des niches situées dans d'autres régions de l'espace de recherche sont augmentés. Les algorithmes génétiques s'adaptent bien à ce type de contraintes en fournissant des solutions rapidement même si celles-ci ne sont pas forcément optimales.

Un autre avantage de ce type de méthodes est qu'il n'est pas nécessaire de développer de nouveaux outils pour l'intégration d'une nouvelle application. Seule l'expertise et une bonne représentation du problème sont nécessaires (cf. paragraphe 8).

6.2 AGMC

Les méthodes d'optimisation utilisant des algorithmes génétiques permettent d'apporter des réponses satisfaisantes là où les méthodes classiques d'optimisation échouent face à la dimension de l'espace de recherche des solutions. Les algorithmes génétiques, basés sur le principe de sélection de Darwin [Darwin 1859] et introduits par Holland [Holland 1975], font évoluer une population d'individus.

Un individu est doté d'un génome. Ce génome représente les critères d'un problème à optimiser. Cette évolution se fait à travers plusieurs générations constituées de différentes étapes. Les individus sont d'abord évalués à l'aide d'une fonction d'évaluation appelée fitness qui mesure le degré d'élitisme d'un individu. Ensuite certains de ces individus sont sélectionnés et on leur applique des opérateurs. Il y a deux types d'opérateurs : un opérateur de croisement et un opérateur de mutation. Ils permettent l'émergence d'individus adaptés à leur environnement. Les individus les plus adaptés (the fittest) tendent à survivre plus longtemps et à se reproduire plus aisément.

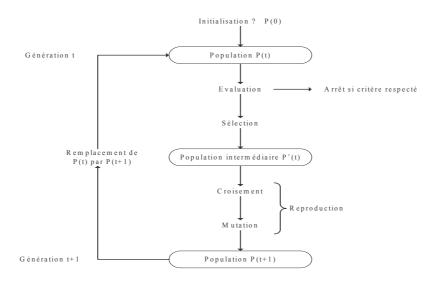


FIG. 6 - Fonctionnement d'un algorithme génétique

Le mécanisme d'évolution et de sélection est indépendant du problème à résoudre, mais pour que ces générations donnent un résultat satisfaisant, il faut résoudre deux problèmes qui sont le paramétrage et l'écriture de la fonction d'évaluation. Il n'existe pas de paramètres qui soient adaptés à la résolution de tous les problèmes. Une approche prudente et pragmatique consiste à essayer différents paramètres et à choisir les meilleurs résultats. En ce qui concerne la fonction d'évaluation elle est liée au problème à optimiser. L'utilisateur a donc un rôle important puisqu'il doit définir un bon système d'évaluation.

La bibliothèque des algorithmes génétiques multi-critères, l'AGMC, développée par l'équipe Synthèse d'Images et Réalité Virtuelle (SIRV) de l'IRIT-UT1, permet d'optimiser un problème et de prendre facilement en compte les contraintes spatiales [Berro et Sanchez, 2000]. Les problématiques qui peuvent être intégrées sont nombreuses et peuvent s'avérer très intéressantes dans des domaines variés comme l'optimisation de placements, la simulation comportementale, les phénomènes d'agglomération urbaine et périurbaine, l'analyse spatiale des marchés... De plus, nous avons choisi d'intégrer un moteur de visualisation 3D, VirtualGéo, permettant de mettre en évidence les résultats issus de l'optimisation d'une problématique par l'AGMC.

7. Exemple de type de problèmes traités

Les problèmes traités par la plate-forme DynaSpat sont généralement des problèmes de placement. On recherche la configuration optimale d'entités dans un espace donné répondant à un ensemble de critères prédéfinis ou évoluant au cours du temps (interaction avec l'utilisateur). La complexité de tels problèmes croit exponentiellement en fonction du nombre de placement à prendre en compte.

Soit x et y les dimensions d'un espace de recherche continu et soit n le nombre d'entités à placer. Si on teste toutes les possibilités de placement alors la complexité d'un tel algorithme est de l'ordre de $O((x \times y)^n)$

Pour un nombre important d'entités (>20), les temps de calcul sont de l'ordre de la dizaine d'heures si on veut obtenir la solution optimale. De plus, la complexité grandit si l'on augmente le nombre de variables dépendantes à optimiser et, de ce fait, il devient difficile de trouver une solution optimale sans l'utilisation de métaheuristiques.

La plate-forme se doit de pouvoir répondre à d'autres types de problèmes d'optimisation du même ordre. Dans la partie suivante nous détaillerons un de ces problèmes.

8. Application

8.1 Données

A l'occasion de l'étude d'une base de données de 22 783 sinistres fournie par le SDIS (Service départemental d'incendie et de secours) de la Haute Garonne, nous avons déterminé une problématique : la distribution optimale d'un ensemble de trente casernes sur la Haute-Garonne. L'objectif est de répartir au mieux la gestion des sinistres entre les casernes. Un algorithme génétique effectue une optimisation pour trouver simultanément leur position, leur capacité maximale de gestion des sinistres et leur rayon d'action.

8.2 Représentation du problème et paramétrage

8.2.1 Représentation

Un chromosome représente 30 casernes. Chacun des gènes, qui représente donc une caserne, est constitué de différentes valeurs correspondantes aux critères à optimiser : une capacité de gestion de sinistres, un rayon d'action, une position et un ordre de priorité, il s'agit donc ici d'une optimisation multi-critères.

30 4500.0 5 0		30	4900.0	5	6
---------------------	--	----	--------	---	---

FIG. 7 - Représentation d'un gène

Sur la figure 7, le chiffre 30 représente la capacité de gestion de sinistres, 4900.0 le rayon d'action en mètres, 5 le numéro de la commune sur laquelle sera positionnée la caserne, et 6 un ordre de priorité.

8.2.2 Paramétrage

Pour ce problème, nous avons choisi un taux de mutation de 5% et un taux de croisement de 65%. Nous avons noté les individus de la façon suivante : si la caserne a une capacité de gestion de sinistres égale au nombre de sinistres qu'elle traite réellement alors elle obtiendra une note maximale de 1, sinon cette note se voit diminuer du pourcentage de sur ou sous activité auquel elle doit faire face. De cette manière nous pénalisons les casernes intervenant sur un grand nombre de sinistres au détriment de la capacité d'action des autres casernes.

8.2.3 Résultats

Voici un graphique qui représente l'évolution de la note du meilleur individu au cours des générations successives. Il s'agit d'une population constituée de 400 individus générés aléatoirement. Une population trop faible ne convergera pas vers une solution optimale, alors qu'une population trop grande convergera mais en un temps plus long.

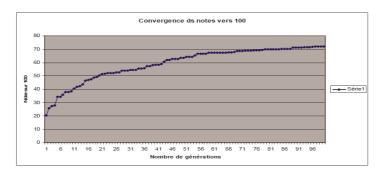


FIG. 8 - Evolution de la note du meilleur individu au cours des générations successives (note sur 100)

L'évolution est alors arrêtée au bout d'un certain nombre d'itérations en fonction des contraintes de temps. Après plusieurs simulations, nous constatons que 100 itérations semblent être un bon compromis pour obtenir une solution quasi optimale en un temps raisonnable.

A partir du résultat final des générations successives, une représentation graphique de ce dernier est visualisable dans VirtualGéo. Dans cette représentation graphique, nous disposons d'un cône, ayant un rayon proportionnel au rayon d'action, et d'une couleur représentant la capacité.

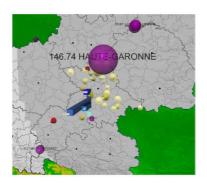


FIG. 9 - Représentation graphique des centres de pompier

Nous pouvons constater (figure 9) que la grande majorité des cônes, donc des casernes, sont concentrés dans la région du nord de la Haute-Garonne, et notamment aux environs de Toulouse. Cette simple constatation renforce la validité des résultats, car en réalité, les sinistres sont effectivement concentrés au nord de la Haute-Garonne et plus précisément aux alentours de Toulouse.

8.2.4 Perspectives

La plate-forme DynaSpat dans sa version actuelle permet de supporter les applications d'optimisation et d'analyse des dynamiques spatiales. Afin d'étendre la palette de simulation et donc l'impact industriel, nous allons intégrer les mécanismes de « classeurs » qui permettent de simuler le comportement d'acteurs virtuels (ou d'agents en général) dans un environnement 2D ou 3D. Cette extension permettra de supporter des applications industrielles dans le domaine de la gestion des risques majeurs, entendues dans un sens assez large, c'est à dire non seulement la gestion des secours en cas de catastrophes, réservée aux secours et aux urgences, positionnement de valises de télémédecine, étude et gestion de la pollution sonore ou agricole.

9. Conclusion

Les représentations de données qu'elles soient graphiques ou cartographiques sont essentielles pour permettre à l'utilisateur d'extraire de l'information utile. Il faut cependant qu'elles soient claires et simples car leur rôle est de présenter l'information de manière plus compréhensible qu'une table ou du texte. La navigation peut permettre à l'utilisateur d'avoir plusieurs points de vue sur l'information. De plus, cette représentation est améliorée par une interaction. En effet, il semble primordial que l'utilisateur puisse manipuler les données qu'il visualise afin qu'il puisse prouver ou mettre en évidence des relations ou des informations isolées.

La reconduite du projet DynaSpat pour deux ans nous permet d'envisager les améliorations à apporter à la plate-forme. En économétrie spatiale, il serait intéressant d'implémenter d'autres choix de construction de matrices de contiguïté (basées sur une distance seuil, sur un nombre de proches voisins, sur une densité locale de sites). Il faudrait également développer des tests d'auto-corrélation spatiale pour variables qualitatives (join-

counts) et graphiques associés. Un troisième volet de la statistique spatiale est actuellement absent de GéoXp: il s'agit du domaine des processus ponctuels dans lequel il serait intéressant d'implémenter les fonctions de test de répartition aléatoire de points, d'estimation d'intensité, de mesure de concentration spatiale.

Le fort potentiel, du prototype V1 de DynaSpat, pour l'identification de données pertinentes et les simulations de stratégies, a permis la construction de groupes de travail autour de plusieurs thèmes : le groupe « GéoFormation » dont le thème principal concerne l'attractivité territoriale au regard des flux de mobilité et des trajectoires des individus en formation et des travailleurs, le groupe « GéoRéseaux » s'intéresse à l'émergence de réseaux et de structures associés à un territoire, et enfin le groupe « Ruralité » travaille sur le coût de la ruralité dans l'enseignement secondaire. Les applications qui résulteront de ces groupes permettront de montrer l'étendue des possibilités de la plate-forme.

Références

- [Aragon et al., 2003] Y. Aragon, O. Perrin, A. Ruiz-Gazen, C. Thomas-Agnan. Statistique et Econométrie pour données géoréférencées : modèles et études de cas, 2005.
- [Beasley et al., 1993a] D. Beasley, D.R. Bull et R.R. Martin, An Overview of Genetic Algorithms: Part 1, Fundamentals, *University Computing*, vol. 15, n°2, p. 58-59, 1993a.
- [Beguin et Pumain, 1994] M. Beguin et D. Pumain .La représentation des données géographiques : Statistiques et cartographie, *Armand Colin*, 1994.
- [Berro et Duthen, 2001] A. Berro et Y. Duthen. Search for optimum in a dynamic environment an efficient Agent-Based Method, *GECCO-2001 Workshop on Evolutionary Algorithms for Dynamic Optimization Problems*, San Francisco, USA, 2001.
- [Berro et Sanchez, 2000] A. Berro et S. Sanchez. Optimisation pat Algorithme Génétique du placement des succursales d'une entreprise, *ROADEF 2000 (Recherche Opérationnelle et Aide à la Décision Française)*, Nantes, 2000.
- [Bertin, 1977] J. Bertin. La graphique et le traitement graphique de l'information, Flammarion, Paris, 1977.
- [Besse, 2003] P. Besse. Data mining, Modelisation Statistique & apprentissage, 2003.
- [Burrough, 1986] P.A. Burrough. Principles of geographical information systems for land resources assessment, *Oxford*, *Clarendon Press*, 1986.
- [Cleveland et McGill, 1984] W. Cleveland et R. McGill. Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods, *Journal of the American Statistical Association*, 79, pp.531-554, 1984.
- [Cressie, 1993] N. Cressie. Statistics for spatial data, John Wiley & Sons, New York, 1993.
- [Darwin, 1859] Darwin. Sur l'origine des espèces, Garnier Flammorion GF 685, 1992.
- [Goldberg, 1994] D. Goldberg. Algorithmes génétiques, exploration, optimisation et apprentissage automatique, *Paris: Addison-Wesley*, 1994.
- [Goldenweiser, 1916] E. A. Goldenweiser. Classification and Limitations of Statistical Graphics, *Publications of the American Statistical Association, Volume 15, Issue 114 (Jun.)*, pp.205-509, 1916.
- [Hardle, 1990] W. Hardle. Applied Nonparametric Regression, volume 19 of Econometric Society Monographs. Cambridge University Press, 1990.
- [Healey, 1996] C.G. Healey. Choosing Effective Colours for Data Visualization. *In Proceedings IEEE Visualization '96* (San Francisco, California, 1996), pp. 263-270.

- [Heba et al., 2003] I. Heba, E. Malin et C. Tomas-Agnan. Exploratory Spatial Data Analysis with GeoXp, *submitted to Geographical Analysis*, 2003.
- [Heba et al., 2003] I. Héba, J. Le Sage, A. Ruiz-Gazen et C. Thomas-Agan. GeoXp for Spatial Exploratory Data Analysis with Matlab Demonstration, *Communication au colloque de la Regional Science Association International*, Philadelphie, 2003.
- [Holland, 1975] J.H. Holland. Adaptation in Natural and Artificial Systems, *University of Michigan Press, Ann Arbor, 1975. Republished by the MIT Press, 1992.*
- [Lavigne et Sanchez, 2002] S. Lavigne et S. Sanchez. Cognitive institutions and coordination of investment's decisions. A model of Learning on a artificial stock market, Workshop on Economics with Heterogeneous Interacting Agents (WEHIA), Trieste Italie.
- [Myers, 2000] D.F. Meyers. Psychology (6th edition), Worth Publishing, 2000.
- [Monmonier, 1989] M. Monmonier, Geographic brushing, enhancing exploratory analysis of the scatterplot matrix, *Geographical Analysis*, Vol. 21, pp. 81-84, 1989.
- [Poulet, 2002] F. Poulet. La visualisation de connaissances, *Tutoriel EGC'2002, 2e Journées Extraction et Gestion de Connaissances*, Montpellier, 2002.
- [Pumain et Saint-Julien, 1997] D. Pumain et T. Saint-Julien. L'analyse spatiale, *Armand Colin, « Cursus »*, Paris, 1997.
- [Schneiderman, 1996] B. Schneiderman. The Eyes Have It: A Task by Data Type Taxonomy for Information Visualization. IEEE/CS Symposium on Visual Languages (VL'96), IEEE CS Press.
- [Triesman 1985], A. Triesman. Preattentive processing in vision. *Computer Vision, Graphics and Image Processing 31*, 156–177.
- [Triesman, 1991], A. Triesman. Search, similarity, and integration of features between and within dimensions. *Journal of Experimental Psychology: Human Perception & Performance* 17, 3, 652–676.
- [Triesman et Gormican, 1988] A. Triesman et S. Gormican. Feature analysis in early vision: Evidence from search asymmetries. *Psychological Review 95*, 15–48.
- [Tufte, 1983] E. Tufte. The visual Display of Quantitative Information, *Graphics Press, Cheshire*, Connecticut, 1983.
- [Turkey, 1977] J.W. Turkey. Exploratory Data Analysis. Reading: Addison-Wesley Publishing CO.
- [Vallée, 1996] R. Vallée. Cognition et système Essai d'épistémolopraxéologie, L'interdisciplinaire, coll. Système(s), Paris 1996.
- [Wilkinson, 1999] L. Wilkinson, The Grammar of Graphics, New York: Springer-Verlag.
- [Wise et al., 2001] S. Weise R., J. Haining et J. Ma. Providing spatial statistical analysis functionality for the GIS user: the SAGE project, *Int. J. Geographical Information Science*, pp. 239-254, 2001.
- [Zeitouni, 1998] K. Zeitouni. Etat de l'art sur l'extension du data mining aux bases de données géographiques, *Rapport de Recherche, Laboratoire Prism*, Université de Versailles, 1998.

Annexe 1

angleplot	Cette fonction met en évidence les directions dans lesquelles la	
	variable présente des tendances. Elle relie une carte et un nuage de	
	points. Le graphique statistique consiste à présenter pour tous les	
	couples de sites dont le segment forme un angle σ (en radian) avec	

	l'horizontale, la valeur absolue de la différence entre les valeurs de
	la variable étudiée en ces sites.
bar	Cette fonction relie une carte et un diagramme en bâtons. Elle est très semblable à la fonction « histogram » (voir ci-dessous) dans son utilisation, la différence étant que la variable donnée en entrée est une variable qualitative. Le nombre de barres du diagramme est donc le nombre de modalités de la variable. Les sélections se déroulent de la même façon que pour la fonction « histogram ».
boxplot	Cette fonction met en relation une carte et la boite à moustaches d'une des variables. La sélection ne peut se faire que sur la boite à moustaches car la sélection inverse n'aurait pas de sens. Sur le graphique statistique, on peut sélectionner des intervalles interquartiles ou des points atypiques (des points en dehors de la boite). Les unités correspondantes sur la carte sont alors mises en évidence.
cluster	Cette fonction permet d'effectuer une classification d'une série de variables sélectionnées par l'utilisateur au moyen de la méthode des k-means. Ce dernier a le choix entre deux variantes de la méthode des k-means (classification des données associées à des sites ou des distances inter sites) et doit choisir le nombre de classes qu'il désire obtenir. Le résultat de cette classification est une variable qualitative et on utilise un diagramme en bâtons pour représenter les différentes classes. La fonction met donc en relation une carte et un diagramme en bâtons. Les différentes classes sont distinguées en utilisant des couleurs différentes pour chacune d'entre elles à la fois sur le diagramme et sur la carte. Les sélections se déroulent exactement comme pour la fonction « histogram ».
dblebar	Cette fonction met en relation une carte et deux diagrammes en bâtons pour étudier deux variables qualitatives. L'utilisation est très similaire à celle de la fonction « bar ». Lorsqu'une sélection est effectuée sur la carte ou sur l'un des deux graphiques, celle-ci est répercutée immédiatement sur les deux autres graphiques (carte incluse).
dbledensity	Cette fonction met en relation une carte et deux estimateurs à noyau de la densité. Ces estimateurs sont calculés de la même façon que dans la fonction « density » (voir ci-dessous) pour les deux variables sélectionnées par l'utilisateur. Ce dernier dispose de deux réglettes pour régler indépendamment le paramètre α de chacun des estimateurs. Les sélections se font de la même manière que pour la fonction « density » et se répercutent sur tous les graphiques.
dblehistogram	Cette fonction relie une carte et deux histogrammes. L'utilisateur peut choisir un nombre de classes pour chacun des histogrammes. Les sélections s'effectuent de la même façon que pour la fonction « histogram » (voir ci-dessous).
density	Cette fonction met en relation une carte et un estimateur à noyau de la densité. Cet estimateur est calculé par la formule suivante [Hardle, 1990]: $\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^{n} K(\frac{x-x_i}{h})$ où \mathbf{x}_i sont les observations de la variable étudiée sur les unités i,

	K est une fonction noyau prise égale à	
	$K(x) = \frac{35}{32}(1-x^2)^3$	
	$\int_{-\infty}^{\infty} (\lambda) = \frac{1}{32} (1 - \lambda)$	
	h est un paramètre, appelé la fenêtre. Par défaut, le programme	
	calcule h suivant la formule suivante :	
	$h = \frac{\alpha}{200} (\max_{i} (x_i) - \min_{i} (x_i))$	
	-00	
	où α est un paramètre rentré par l'utilisateur compris entre 0 et 100 et que ce dernier peut modifier à tout moment à l'aide d'une réglette. La sélection d'unités sur la carte a pour effet de faire apparaître l'estimateur à noyau de la sous-densité calculé uniquement avec les observations de la variable étudiée correspondant à ces unités. La sélection sur la densité consiste à choisir un ou plusieurs intervalles sur l'axe des abscisses et a pour effet de faire apparaître sur la carte les unités pour lesquelles la variable tombe dans ces intervalles.	
drift	La fonction « drift » est une fonction non interactive. On superpose	
arm	à la carte une grille régulière et on calcule, pour chaque ligne et pour chaque colonne de la grille, la moyenne et la médiane de la variable étudiée que l'on représente en regard de la carte sur un graphique à droite pour les lignes, et au dessous pour les colonnes.	
	L'examen des variations des moyennes par ligne et par colonne	
	permet alors de détecter des tendances nord-sud ou est-ouest pour la	
	variable concernée. Les disparités entre moyennes et médianes	
. • . •	permettent de localiser les points atypiques.	
gini	Cette fonction met en relation une carte et un diagramme de Gini (courbe de Lorentz). La courbe est calculée à partir de la variable sélectionnée par l'utilisateur de même que l'indice de Gini qui est affiché près du graphique et qui est égal à l'aire entre la courbe et la première bissectrice. La courbe est tracée en interpolant linéairement les points (F_k, G_k) où :	
	$F_k = \frac{1}{n} \sum_{i=1}^n I(X_i \le X_k)$	
	où n est le nombre d'observation, k est le nombre de valeurs	
	distinctes des X_i et $I(X_i \le X_k) = \begin{cases} 1 \text{ si } X_i \le X_k \\ 0 \text{ si } X_i > Xk \end{cases}$	
	$G_k = \sum_{l=1}^k g_l \text{avec} g_k = \frac{X_k f_k}{\frac{1}{n} \sum_{i=1}^n X_i}, \text{et}$	
	$f_{k} = \frac{1}{n} \sum_{i=1}^{n} I(X_{i} = X_{k})$	
	La sélection ne s'effectue que sur le graphique statistique sur lequel l'utilisateur peut choisir une abscisse. La valeur de la variable correspondant à ce point est calculée et affichée ainsi que	
I	les fréquences F_k et G_k correspondantes.	

litatalian	Cotto fonction mot on valetion and control to
histobar	Cette fonction met en relation une carte, un histogramme et un diagramme en bâtons. L'utilisateur peut choisir le nombre de classes de l'histogramme. Les sélections s'effectuent de la même façon que dans la fonction «histogram» (voir ci-dessous) ou « bar » et se répercutent sur tous les graphiques.
histogram	Cette fonction met en relation une carte avec un histogramme. L'utilisateur peut choisir le nombre de classes de l'histogramme. Il peut effectuer des sélections soit sur la carte soit sur le graphique. La sélection d'unités spatiales sur la carte a pour effet de faire apparaître la sous distribution des unités choisies sur l'histogramme. La sélection sur l'histogramme consiste à choisir une ou plusieurs classes et a pour effet de mettre en valeur sur la carte les unités spatiales qui appartiennent à la classe.
mdsmap	Cette fonction effectue une analyse d'échelle multidimensionnelle à partir d'un ensemble de variables données par l'utilisateur en entrée. Elle relie une carte au nuage de dispersion résultant de cette analyse. Les sélections s'effectuent de la même façon que pour la fonction « scatterplot » (voir ci-dessous).
moranplot	Cette fonction met en relation une carte et un diagramme de Moran. On se donne une matrice de poids W indiquant des relations de voisinage entre les unités spatiales. On fabrique la variable dite « décalée » WX obtenue en multipliant la variable initiale par la matrice de poids. Le diagramme de Moran est alors un simple diagramme de dispersion de WX contre X sur lequel on superpose la droite d'ajustement linéaire. On calcule l'indice de Moran global et la p-value que l'on affiche près du graphique dont voici les formules : $I_{global} = \frac{n}{m} \sum_{i=1}^{n} (X_i - \overline{X})(X_j - \overline{X})$ où n est le nombre d'observations et m est le nombre de couples voisins (chaque paire est comptée deux fois, un point n'étant jamais voisin de lui-même). La p-value permet de juger la vraisemblance de l'observation (plus elle est petite, moins l'observation est vraisemblable). $pvalue = 1 - normcdf(I_{normalisé}, 0, 1)$ où normcdf(x, 0, 1) calcule la fonction de répartition de la gaussienne standard évaluée en x. Notons que $I_{normalisé}$ est obtenu en retranchant à I_{global} sa moyenne et en le divisant par son écart-type. Pour chaque point du nuage, on calcule également l'indice de Moran local grâce à la formule suivante : $I_i = \sum_j w_{ij} (X_i - \overline{X})(X_j - \overline{X})$
neighbour	Cette fonction met en relation une carte et un diagramme des voisins. Un diagramme des voisins pour une variable X est un simple diagramme de dispersion contenant les points d'abscisse X_i pour l'unité spatiale i et d'ordonnée X_j pour les unités spatiales j voisines de i c'est-à-dire telles que $W_{ij}\neq 0$. W est une matrice de contiguïté donnée en entrée par l'utilisateur. Un point du graphique

	statistique correspond donc à deux points sur la carte, voisins au sens de W.
pcamap	Cette fonction effectue une analyse en composantes principales à partir d'un ensemble de variables donné par l'utilisateur. Ce dernier peut choisir les directions principales qu'il souhaite prendre comme axe, il peut choisir s'il souhaite que les données entrées soient centrées et/ou réduites. Il peut également entrer un vecteur de poids s'il souhaite pondérer les observations (échantillon redressé). La fonction met en relation une carte et le nuage de points résultant de l'analyse. Sur chaque axe du nuage de points, la part d'inertie de l'axe en pourcentage est affichée. Une seconde fenêtre est également ouverte où est dessiné le diagramme des variables. C'est un nuage de points comptant autant de points que de variables rentrées au départ et qui permet de visualiser la distance des variables aux axes.
polybox	Cette fonction permet d'afficher plusieurs boites à moustaches. L'utilisateur sélectionne une variable quantitative et une variable qualitative, une boîte à moustaches est affichée pour chaque modalité de cette variable. Les sélections se déroulent comme pour la fonction « scatterplot » (voir ci-dessous).
pprmap	Cette fonction effectue une analyse exploratoire par projection poursuite à partir des variables sélectionnées par l'utilisateur. Elle affiche un nuage de points correspondant à la projection la plus pertinente choisie par l'algorithme. Lorsque des points sont sélectionnés sur le graphique ou la carte, les points correspondants sont mis en valeur sur le graphique en regard.
sarmap	Cette fonction ajuste un modèle spatial autorégressif (SAR) à une sous région d'une carte. La fenêtre ouverte ne présente pas de graphique statistique. Ce dernier est remplacé par un tableau comportant deux colonnes. La première contient les paramètres estimés du modèle SAR calculés à partir de tous les points de la carte, pour un ensemble de variables explicatives, et une variable à expliquer sélectionnée par l'utilisateur. La sélection de points sur la carte entraîne l'affichage dans la seconde colonne du tableau de ces mêmes paramètres mais calculés uniquement à partir des informations concernant la sous sélection.
scatterplot	Cette fonction met en relation une carte et un simple diagramme de dispersion pour deux variables données.
semmap	Cette fonction ajuste un modèle à erreurs spatialement corrélé à une sous région d'une carte. Cette fonction est très proche de la fonction « sarmap ». La seule différence vient du modèle et des paramètres qui sont calculés et affichés dans le tableau de droite. Le système de sélection est identique.
sirmap	Cette fonction effectue un ajustement en utilisant une méthode dite de régression inversée par tranche avec une série de variables explicatives et une variable à expliquer sélectionnées par l'utilisateur. Elle met en relation une carte et un nuage de points. L'utilisateur peut également choisir quelles sont les directions edr qu'il souhaite afficher (chaque couple de directions correspond à un nuage de points différent). Un lissage du nuage de points est systématiquement superposé au nuage et le paramètre α contrôlant

	la fenêtre h est réglable grâce à une réglette. Les sélections sont semblables à celles présentes dans les autres fonctions comportant des nuages de points.	
variocloud	Cette fonction met en relation une carte et un nuage de variogramme. Ce type de graphique statistique consiste à représenter en fonction de la distance d le demi carré de la différence entre deux valeurs de la variable étudiée en deux points distants de d pour tous les couples satisfaisant cette condition.	

Annexe 2

Description des modules :

- AGMC :
 - Ecrite en C++,
 - 34 classes,
 - 32 000 lignes de codes,
- GéoXp :
 - Ecrite en C++,
 - 26 classes,
 - 24 372 lignes de codes,
- Manager (contrôleur et gestionnaire des différents modules) :
 - Ecrit en C++,
 - 19 classes,
 - 24 758 lignes de codes.

Summary

The DynaSpat platform is a simulation and visualization tool for the description, analysis and modelization of the behaviour of economic agents. It combines a set of softwares and libraries that allows running simulation based upon genetic algorithms and summarizing the complex structure of a data base in set of relevant variables. It thus allows several applications aiming at the understanding of the mutual influence between country structuring and the behaviour of socio-economic agents.